

Partie 1 - Machine Learning Avancé

Le Bureau d'Analyse Terrestre : le Conseil renvoie le rapport



Ce qui s'est passé pendant la nuit

Oui il n'a pas vraiment fait nuit, je sais. Disons que la planète étant petite, le cycle jour nuit est plutôt rapide.

Votre rapport est passé devant le Conseil. Il n'a pas été rejeté, ce qui est déjà un exploit au Bureau (bravo). Il a été **renvoyé avec annotations**. Comme les profs qui corrigent des copies en écrivant juste "pas mal" en haut, sans rien avoir annoté, eux ils ont écrit une phrase : « *nous voulons bien vous croire, mais montrez-nous que ces chiffres survivent à un examen sérieux* » (mais tu m'as lu au moins ? bref).

Le Conseil a mis six objections dans la marge. Chacune attaque un endroit précis de votre méthode (pas de vos résultats). C'est plus embêtant, parce qu'une méthode fausse produit des chiffres qui ont l'air très bien.

Une chose à savoir avant de commencer : vos deux nombres vont probablement baisser dans cette partie. C'est normal et c'est même le but. Un chiffre qui descend quand on retire une triche, c'est un chiffre qui était faux avant. **Le Conseil préfère 30 % d'honnête à 90 % de fantaisie**, et il vous le fera savoir.

On continue dans le même repo, avec le même `analyse.py`, le même `RAPPORT.md`, les commits propres très réguliers. Une section par phase, comme avant.

Phase 7 : plusieurs témoins, un seul événement

Première annotation du Conseil, et elle est signée par le conseiller à la cartographie :

« Une nuit d'automne 2004, quelque chose est passé au-dessus de Tinley Park. Nous avons reçu des dizaines de signalements de cette seule nuit, écrits par des gens différents qui décrivent la même chose. Votre système en a-t-il vu une partie pendant son apprentissage, et a-t-il été noté sur le reste ? »

Prenons le temps sur celle-là, elle est vicieuse.

Un truc passe dans le ciel au-dessus d'une ville. Ce n'est pas un relevé qui arrive au Bureau, c'en est trente. Trente personnes ont vu la même chose le même soir, chacune écrit son témoignage dans son coin, et ça fait trente lignes dans le fichier. Trente lignes qui se ressemblent énormément, forcément.

Maintenant, coupez votre fichier en deux : une partie pour apprendre, une partie pour noter. Ces trente lignes-là, elles partent au hasard des deux côtés. Disons vingt-quatre pour apprendre et six pour noter.

Vous voyez venir le problème ? Le jour de l'examen, votre système tombe sur six relevés qui racontent une soirée dont il a déjà lu vingt-quatre versions. Il ne détecte rien du tout. **Il reconnaît.** Et il a une très bonne note.

Ce qui est exigé. Deux choses, dans cet ordre.

D'abord, trouver comment repérer, avec les colonnes du fichier, que deux relevés parlent du même événement. Deux témoins d'une même apparition, en somme.

Ensuite, refaire votre découpe autrement : tous les relevés d'un même événement partent du même côté. Soit ils sont tous dans l'apprentissage, soit ils sont tous dans le test, jamais répartis entre les deux.

Rendez ces quatre nombres :

- combien d'événements ont été signalés par plus d'un témoin,
- combien de témoins pour le plus gros d'entre eux,
- combien de relevés étaient à cheval sur les deux côtés dans votre découpe d'hier,
- les deux nombres de la phase 4, avant et après la nouvelle découpe.

Il existe un cas encore plus grossier, dans le fichier : des témoignages recopiés à l'identique, mot pour mot, sur plusieurs lignes. Comptez-les et dites ce que vous en faites.

Validé quand votre rapport dit noir sur blanc quelles colonnes vous utilisez pour reconnaître un même événement, et que vous pouvez afficher à l'écran un événement entier, tous ses témoins alignés, tous du même côté.

Phase 8 : l'ordre des choses

Deuxième annotation, du conseiller aux opérations :

« Votre système servira sur des transmissions qui ne sont pas encore arrivées. Est-ce que vous l'avez testé sur des relevés plus récents que ceux sur lesquels il a appris, ou est-ce qu'il a eu le droit de lire l'avenir ? »

Regardez la découpe que vous venez de refaire. Vous avez mis de côté une partie des relevés pour noter votre système. Dans cette partie, il y a des observations de 1998 et des observations de 2013, mélangées.

Ce qui veut dire qu'au moment où votre système se prononce sur un relevé de 1998, il a déjà lu quinze ans de la suite de l'histoire. Il connaît les mots que les témoins emploieront en 2010. Il sait comment le Bureau annotera les dossiers en 2008. Personne, au Bureau, n'a jamais eu cette chance.

Il y a deux dates dans la transmission et elles ne racontent pas la même chose. L'une dit quand le témoin a levé les yeux. L'autre dit quand le Bureau a reçu le dossier. Choisir celle sur laquelle vous coupez est une décision, et elle se défend.

Ce qui est exigé. Refaire la découpe dans l'ordre du temps. Tout ce qui sert à apprendre est plus ancien que tout ce qui sert à noter, sans exception.

Rendez :

- la date de coupure,

- le nombre de relevés de chaque côté,
- la proportion de canulars de chaque côté,
- les deux nombres de la phase 4 après cette découpe,
- une phrase disant laquelle des deux dates vous avez utilisée pour couper, et pourquoi celle-là.

Validé quand les deux proportions de canulars sont dans le rapport, côte à côte. Regardez-les bien avant de passer à la suite : si elles ne sont pas égales, vous venez de mettre la main sur quelque chose d'important, et ça se raconte en deux lignes.

Phase 9 : les cases vides

Troisième annotation. Elle est courte :

« 12 365 relevés sans pays. Qu'est-ce que vous en avez fait, et qu'est-ce que ça vous a coûté ? »

Un stagiaire du Bureau propose deux solutions : jeter ces lignes, ou remplir les trous avec la valeur la plus fréquente. Le Conseil trouve les deux idées raisonnables, ce qui devrait vous inquiéter.

Parce qu'un trou, ce n'est pas rien. C'est quelqu'un qui n'a pas rempli une case, et il y avait une raison. Un témoin pressé. Un signalement bâclé à trois heures du matin. Un dossier que personne au Bureau n'a jugé digne d'être complété.

Alors peut-être que les relevés troués ne se comportent pas du tout comme les autres. Ou peut-être que si, aucune idée. Mais tant que vous ne l'avez pas mesuré, boucher le trou revient à effacer une pièce à conviction avant de l'avoir regardée.

Et ça se mesure vite : chez les relevés qui ont un trou dans une colonne, quelle proportion de canulars ? Et chez ceux qui n'en ont pas ?

Ce qui est exigé. Prendre les trois colonnes les plus trouées et, pour chacune, comparer ces deux proportions. Ensuite seulement, choisir un traitement.

Rendez :

- les deux proportions pour chacune des trois colonnes, dans un tableau,
- le traitement que vous avez retenu,
- une phrase expliquant en quoi il ne détruit pas ce que vous venez de mesurer.

Validé quand les six proportions sont dans le rapport, et que votre modèle est toujours capable de savoir qu'il y avait un trou à cet endroit. Boucher un trou et effacer sa trace, ce sont deux choses différentes.

Phase 10 : la chaîne de traitement du Bureau

Quatrième annotation, et c'est celle qui fait le plus mal :

« Vos moyennes, vos encodages, vos vocabulaires : vous les avez calculés sur quoi, exactement ? »

Refaites le film de votre travail depuis hier. Vous avez chargé le fichier, nettoyé, converti les types, encodé les colonnes, et **ensuite** vous avez coupé en deux. C'est l'ordre naturel, c'est l'ordre que tout le monde applique, et c'est le mauvais.

Un exemple minuscule pour voir pourquoi. Vous remplacez les durées manquantes par la médiane de la colonne. Cette médiane, vous l'avez calculée sur le fichier entier, donc en partie sur des relevés qui sont maintenant dans votre partie test. Une miette de la partie test vient de passer dans l'apprentissage.

Une médiane toute seule, ce n'est pas dramatique. Ajoutez un vocabulaire de mots, une liste de catégories, une moyenne par ville, et la miette devient un repas.

Il y a une deuxième chose dans cette annotation, plus bête et plus dangereuse. À 0,9 % de canulars, une découpe malchanceuse peut vous donner une partie test qui n'en contient presque aucun. Vos deux nombres deviennent alors de la pure décoration.

Ce qui est exigé. Deux choses.

Tout ce qui s'apprend depuis les données (une moyenne, une médiane, une liste de catégories, un vocabulaire) s'apprend sur la partie apprentissage seule, jamais avant la découpe.

Et l'ensemble du traitement se rejoue sur un relevé neuf en un seul appel. Un relevé entre d'un côté, une prédiction sort de l'autre, sans que vous ayez à retaper la moindre étape à la main.

Rendez :

- la proportion de canulars dans chacune de vos parties,
- la démonstration qu'un relevé unique traverse toute la chaîne et ressort avec une prédiction,
- les deux nombres de la phase 4 après correction.

Validé quand aucun calcul appris ne précède la découpe dans `analyse.py`, et que vous pouvez faire passer devant moi une ligne inventée à la main dans votre chaîne, sans rien relancer d'autre.

Phase 11 : combien de temps ça a duré

Cinquième annotation, du service scientifique :

« Nous aimerions savoir combien de temps durent ces apparitions. Nous avons deux colonnes de durée dans la transmission, et elles ne sont pas d'accord entre elles. »

Vous avez croisé cette colonne en phase 2, vous savez déjà qu'elle est sale. Ce que vous n'avez peut-être pas remarqué, c'est qu'il y en a deux.

La première est censée être un nombre de secondes, bien propre. La deuxième est ce que le témoin a écrit à la main : « 5 minutes », « 1-2 hrs », « environ une demi-heure ». Le service de transmission a fabriqué la première à partir de la deuxième, et il l'a parfois ratée. Il existe des relevés où la colonne en secondes annonce 0 alors que le témoin, lui, avait écrit une durée parfaitement lisible.

La colonne propre a donc perdu de l'information que la colonne sale a gardée. Ça vaut le coup d'aller voir avant de jeter la sale.

Ce qui est exigé. Une durée utilisable comme un nombre pour le plus grand nombre possible de relevés, sans qu'une seule ligne ne disparaisse au passage.

Rendez :

- le nombre de relevés dont la durée reste inutilisable après votre traitement,
- le nombre de relevés où les deux colonnes se contredisent,
- la durée médiane,

- le nombre de relevés qui annoncent plus d'une journée d'observation.

Puis affichez les trois durées les plus longues du fichier et dites ce que vous en faites. Il y a une décision à prendre là, et la prendre au hasard se voit tout de suite dans la médiane.

Validé quand le nombre de lignes est identique avant et après, que deux natures d'aberration au moins sont nommées avec leur compte, et que vous pouvez afficher un relevé où les deux colonnes de durée racontent deux histoires différentes.

Phase 12 : la ville et l'heure

Dernière annotation, et le Conseil la pose comme un piège :

« Nous voulons que votre système sache où et quand les choses se passent. Votre rapport dit que la transmission contient 22 018 villes. Nous supposons que votre tableau ne fait pas 22 018 colonnes ? »

Deux informations très riches, et deux façons complètement différentes de se planter.

La ville, c'est le problème de la largeur. Si vous fabriquez une colonne par ville, votre tableau passe d'une dizaine de colonnes à vingt-deux mille. Et l'écrasante majorité de ces colonnes ne contiendra qu'un seul 1, parce qu'un paquet de villes n'apparaissent qu'une fois dans tout le fichier. Votre système va donc apprendre par cœur des villes qu'il ne reverra jamais de sa vie.

L'heure, c'est plus sournois, parce que rien ne casse et que personne ne vous prévient. 23h et 0h, c'est une heure d'écart dans le ciel. Sur une règle graduée de 0 à 23, c'est vingt-trois heures d'écart. Votre système croit donc que minuit est le moment de la journée le plus éloigné de 23h, ce qui est absurde, et il continuera de le croire tranquillement jusqu'à la fin.

Ce qui est exigé. Utiliser la ville et l'heure d'observation dans votre modèle, en gardant un tableau dont vous pouvez annoncer la largeur sans avoir honte.

Rendez :

- le nombre de colonnes de votre tableau avant et après,
- la règle appliquée aux villes, en une phrase,
- le nombre de villes qui n'apparaissent qu'une seule fois dans toute la transmission,
- la distance entre 23h et 0h dans votre encodage, et la distance entre 23h et 20h. Deux chiffres, pas une affirmation.

La colonne `shape` mérite le même regard : 29 formes, dont certaines qui n'apparaissent qu'une ou deux fois, et deux paires qui désignent visiblement la même chose sous deux orthographes. Traitez-la et dites combien de formes il vous reste.

Validé quand la largeur du tableau est dans le rapport, que 23h ressort bien plus proche de 0h que de 20h, et que si l'un de vos encodages utilise la cible, il est appris sur la partie apprentissage seule. Celle-là est la faute la plus discrète de la journée, et c'est celle que je cherche en premier.

Avant de passer à la suite

Vos six phases ont chacune fait bouger un chiffre. Le Conseil veut les voir bouger dans `RAPPORT.md`, dans l'ordre, avec une ligne d'explication à chaque fois. Un chiffre qui apparaît sans son avant est un chiffre qu'on ne peut pas juger.

`analyse.py` tourne toujours d'une traite, du téléchargement au dernier nombre. Et les commits continuent, courts et parlants : c'est votre raisonnement que je lis dedans, pas seulement votre code.