

Partie 1 - Machine Learning Avancé

Le Bureau d'Analyse Terrestre : défendre une décision



Le Conseil vous croit, et c'est maintenant que les ennuis commencent.

Vos chiffres ont tenu. Ils sont plus bas qu'hier matin, ils sont propres, et le Conseil les a acceptés. Il y a eu un silence, puis la présidente a posé son stylo et a dit ceci :

« Très bien. Maintenant, qu'est-ce que le Bureau **fait** de ça ? »

C'est une autre question, et beaucoup d'analystes s'arrêtent juste avant. Un système qui sort une probabilité ne décide rien. C'est vous qui décidez, et le Conseil veut savoir sur quelle base.

Le Bureau compte moins de cinquante personnes, il n'a aucune marge, et chaque relevé traité par erreur coûte du temps que personne n'a. Il reste à transformer un score en décision qu'on peut défendre à voix haute.

Toujours le même dépôt, le même `analyse.py`, et le même `RAPPORT.md`.

Phase 13 : la facture du Bureau

Le Conseil arrête de parler en pourcentages et se met à parler en crédits. Voici la grille qu'il a votée, et elle n'est pas négociable :

Le cas	Le coût pour le Bureau
Un canular que votre système laisse passer	30 crédits, une équipe d'analystes part travailler sur du vent
Un relevé honnête que votre système marque comme canular	2 crédits, le Bureau perd une observation potentiellement utile
Un canular correctement attrapé	0
Un relevé honnête correctement laissé passer	0

Votre système ne sort pas une décision. Il sort une probabilité : 0.03 pour celui-là, 0.47 pour celui-ci, 0.82 pour cet autre. Quelque part entre ce nombre et le mot « canular », il a bien fallu tracer une frontière. Au-dessus, on dit canular. En dessous, on laisse passer.

Si vous n'avez rien tracé, c'est que la bibliothèque l'a fait pour vous, et elle a posé la frontière à 0.5. Pourquoi 0.5 ? Pour aucune raison. C'est le milieu, c'est joli. Ça n'a jamais entendu parler du Bureau, et surtout pas du fait qu'un canular raté lui coûte quinze fois plus cher qu'une fausse alerte.

Avec la grille ci-dessus, chaque frontière possible a un prix, et vous pouvez le calculer.

Ce qui est exigé. Trouver la frontière qui coûte le moins cher au Bureau, sur votre partie test, et le prouver avec des crédits.

Rendez :

- la facture en fonction de la frontière, en tableau ou en courbe,
- la frontière retenue,
- la facture à 0.5,
- la facture avec la vôtre,
- l'écart en crédits entre les deux.

Validé quand les deux factures sont dans le rapport avec leur écart, et que votre justification s'appuie sur la grille de coûts. Une justification qui cite un score au lieu de citer des crédits ne répond pas à la question posée.

Phase 14 : une promesse à 80 %

La conseillère qui vous avait piégés hier revient. Elle a lu que votre système annonce des probabilités.

« Prenez tous les relevés pour lesquels votre système a annoncé environ 80 % de chances d'être un canular. Sur cent relevés comme ceux-là, combien en sont vraiment ? Si la réponse n'est pas quatre-vingts, votre système raconte n'importe quoi et je ne peux pas fonder une décision dessus. »

Elle a mis le doigt sur quelque chose de contre-intuitif.

Un système peut très bien trier et très mal chiffrer. Imaginez qu'il range tous les relevés du plus suspect au moins suspect, et qu'il fasse ce classement parfaitement. Super, c'est exactement ce qu'on lui demande. Maintenant il colle un nombre sur chacun, et ce nombre sort d'un calcul qui n'a jamais eu pour objectif d'être exact. Il peut très bien annoncer 0.8 sur un paquet de relevés dont 12 % seulement sont des canulars.

Le classement est bon, le chiffre est faux, et c'est le chiffre que le Conseil lit.

Ça se vérifie sans aucune théorie : prenez tous les relevés à qui votre système a donné à peu près la même probabilité, et comptez combien sont vraiment des canulars.

Ce qui est exigé. Découper l'intervalle des probabilités en tranches. Pour chaque tranche, mettre côte à côte ce que le système a annoncé et ce qui s'est réellement produit.

Rendez :

- le tableau des tranches,
- pour chaque tranche : le nombre de relevés concernés, la probabilité moyenne annoncée, la proportion réellement observée,
- une phrase disant dans quel sens votre système se trompe, trop confiant ou trop prudent.

Si l'écart est net, corrigez-le et remontrez le même tableau après correction.

Validé quand le tableau a au moins cinq tranches, que le nombre de relevés par tranche est visible (une tranche à trois relevés ne prouve rien), et que le sens de l'erreur est nommé.

Phase 15 : deux analystes, deux chiffres

Deux analystes du Bureau rendent leur travail le même jour. Le premier annonce 0,31. Le second annonce 0,34. Le Conseil demande lequel des deux systèmes il doit déployer.

C'est une question truquée, et vous allez expliquer pourquoi.

Allez compter combien de canulars contient votre partie test. Il y en a peu, quelques dizaines sans doute, et vos deux nombres de la phase 4 se calculent entièrement sur cette petite poignée de relevés.

Déplacez trois d'entre eux d'un côté à l'autre de la découpe, et votre chiffre bouge de plusieurs points. Votre modèle, lui, n'a pas changé d'un iota. C'est le tirage au sort qui a changé.

Donc quand vous annoncez 0,31, vous n'annoncez pas 0,31. Vous annoncez quelque chose d'assez large autour de 0,31, et pour l'instant vous ne savez pas de combien.

Ce qui est exigé. Bannir le chiffre nu du rapport. Chaque nombre mis en avant arrive avec sa fourchette, obtenue en refaisant la mesure sur plusieurs découpes différentes.

Rendez :

- votre nombre principal sous la forme d'un intervalle,
- le nombre de découpes utilisées pour l'obtenir,
- la taille de votre partie test,
- le nombre de canulars qu'elle contient réellement,
- la réponse au Conseil sur les deux analystes, en une phrase, avec un argument chiffré.

Validé quand la fourchette vient de plusieurs mesures et pas d'une seule, et que le nombre de canulars présents dans votre partie test est écrit noir sur blanc. Ce dernier nombre explique à lui seul la largeur de la fourchette.

Phase 16 : trois dossiers sur le bureau

Le Conseil pose trois dossiers sur la table. Trois relevés de votre partie test, que vous choisissiez vous-mêmes :

- un que votre système marque canular avec une forte confiance,
- un qu'il marque tout juste au-dessus de votre frontière,
- un canular qu'il a laissé passer.

Pour chacun, la même question : pourquoi votre système a répondu ça ?

« Le modèle a décidé » n'est pas une réponse acceptable devant le Conseil. Personne ne signe un rapport dont la conclusion sort d'une chose que l'auteur ne sait pas expliquer.

En le faisant, vous verrez que la réponse n'est pas de même nature selon le dossier. Ce qui fait basculer le premier n'est pas ce qui fait hésiter le deuxième.

Ce qui est exigé. Produire deux niveaux d'explication, sachant que l'un ne remplace pas l'autre.

Le dossier : pour chacun des trois relevés, ce qui a poussé la décision dans un sens ou dans l'autre.

L'ensemble : sur quoi votre système s'appuie globalement. Une méthode simple si vous n'en connaissez pas d'autre, abîmer une colonne à la fois en mélangeant ses valeurs au hasard, et regarder de combien votre résultat chute. Ce qui ne fait rien chuter ne servait à rien.

Rendez :

- les trois relevés, identifiables dans le rapport, chacun avec son explication,
- le classement des colonnes,
- une phrase sur la colonne dont la place vous a surpris.

Validé quand aucune des trois explications ne se contente de recopier le classement global. Une explication d'ensemble et une explication de dossier ne répondent pas à la même question.

Phase 17 : l'angle mort du Bureau

Le conseiller aux affaires étrangères prend la parole pour la première fois de la semaine.

« Le Bureau prépare une infiltration mondiale. Votre système, lui, a surtout lu des relevés américains. Est-ce qu'il fonctionne aussi bien ailleurs, ou est-ce qu'on est en train de préparer une invasion avec un outil qui ne comprend qu'un seul continent ? »

Il a raison, et vous avez le chiffre depuis hier : quatre relevés sur cinq viennent des États-Unis. Tout ce que votre système a appris, les mots employés, les formes rapportées, les heures, les habitudes de rédaction, vient donc d'un seul endroit du monde.

Le pire, c'est que ça ne se voit pas dans vos deux nombres. Ils sont écrasés par la zone qui pèse le plus lourd. Si votre système marche bien aux États-Unis et lamentablement partout ailleurs, la moyenne reste bonne et le Conseil n'y voit que du feu. Il faut aller regarder zone par zone pour que le trou apparaisse.

Ce qui est exigé. Recalculer vos deux nombres séparément par zone géographique, sur au moins trois zones, et les mettre en face du chiffre global.

Rendez :

- le tableau par zone, avec le nombre de relevés de chaque zone à côté de ses résultats,
- la proportion de canulars par zone, qui n'est pas la même partout,
- votre décision : la même frontière partout, ou une par zone, défendue en trois lignes.

Méfiez-vous d'une zone qui pèse quelques centaines de relevés : elle ne se mesure pas comme une zone qui en pèse soixante-dix mille. La phase 15 vous a donné de quoi dire pourquoi.

Validé quand le tableau contient l'effectif de chaque zone, que l'écart avec le chiffre global est commenté, et que la décision sur la frontière est prise. Ne pas trancher est un choix, mais alors il s'écrit.

Phase 18 : la transmission d'archive

Dernière question du Conseil, et c'est la plus désagréable de la semaine.

« Vos relevés couvrent plusieurs décennies. Est-ce que le Bureau a marqué les canulars de la même façon en 1999 et en 2010 ? Parce que si la règle a bougé, votre système a appris une définition qui n'existe plus. »

Souvenez-vous d'où sort votre étiquette. Ce n'est pas une mesure, ce n'est pas un capteur. C'est une annotation écrite à la main par quelqu'un du Bureau, un jour donné, avec les habitudes de ce jour-là.

Or les habitudes bougent. Imaginez un Bureau qui, pendant des années, ne prend jamais la peine d'écrire « canular » sur un dossier. Puis un nouveau chef arrive, il exige que ce soit noté, et pendant quatre ans tout le monde le note. Puis on se lasse et ça retombe. Rien dans le fichier ne signale ces trois époques.

Votre système, lui, a appris une définition moyenne de toute la période. Et vous êtes en train de l'appliquer à une époque où elle n'a peut-être plus cours.

Ça se voit en un seul graphique : une année en abscisse, la proportion de canulars en ordonnée. Si la courbe est plate, tout va bien. Si elle ne l'est pas, votre modèle a un problème dont il ne se plaindra jamais tout seul.

Ce qui est exigé. Rendre deux mesures, puis répondre à une question ouverte.

- **La courbe** : la proportion de canulars année par année, sur toute la période couverte par la transmission.
- **L'épreuve** : entraîner votre système sur les relevés les plus anciens uniquement, le tester sur les plus récents, et rendre vos deux nombres à côté de ceux de la phase 8.

Reste la vraie question, celle qui n'a pas de réponse propre.

Quand le système tournera au Bureau et qu'un relevé arrivera, **personne ne saura s'il s'agit d'un canular**. La vérité arrive des semaines plus tard, ou jamais. Vous ne pouvez donc pas surveiller vos deux nombres en continu : ils ont besoin de la réponse, et vous ne l'avez pas.

Alors qu'est-ce que vous surveillez ? Trois choses à rendre :

- au moins deux indicateurs calculables sans jamais connaître la vérité,
- à quelle fréquence on les regarde,
- à partir de quel écart on rappelle les analystes.

Validé quand la proportion année par année est dans le rapport, que les deux nombres ancien vers récent y sont, et que vos indicateurs de surveillance ne demandent jamais de connaître la réponse. Un indicateur qui a besoin de l'étiquette est un indicateur qui ne servira jamais.

Le rapport final

Le Conseil ne lira pas votre code. Il lira `RAPPORT.md`, et il le lira d'une traite. (Moi je lirai le code, je vous rassure)

Reprenez-le du début. Une section par phase, chaque chiffre avec ce qu'il valait avant, et vos décisions écrites avec vos mots. Si une phrase a été écrite par une IA à votre place, ça se voit à la lecture, et le Conseil en a beaucoup lu.

`analyse.py` se relance dans un dossier vide, sur une machine neuve, du téléchargement au dernier chiffre, sans intervention. Et il redonne les mêmes nombres qu'aujourd'hui. Si vos résultats bougent d'un lancement à l'autre, il vous manque quelque chose à figer, et le Conseil considère qu'un rapport non reproductible n'a jamais été rendu.

Votre historique de commits raconte la même histoire que le rapport. C'est la seule preuve que le raisonnement est le vôtre.

ALIEN CORPO